

钱思远

中国北京 135-0139-3580

qiansiyuan@stu.pku.edu.cn siriyp@gmail.com

个人主页 SiriYep Google Scholar



个人简介

北京大学计算机学院 HMI Lab 博士生，导师为仇尚航助理教授。研究聚焦具备泛化能力的多模态智能体，探索其在复杂物理与虚拟环境中的感知、推理与行动；重点方向包括视觉-语言-动作模型 (VLA)、世界模型，以及面向长程决策的分层推理与控制架构，相关方法应用于真实机器人移动操作、复杂多阶段机器人任务与游戏环境中的智能体决策。已在 NeurIPS、RSS、ACM MM 与 *Nature Computational Science* 等会议和期刊发表工作，相关成果获 Google Scholar 300+ 次引用，并获 RSS 2026 Embodied4Arts Workshop 最佳论文奖；担任 NeurIPS 2025、ICML 2025/2026、ECCV 2024/2026 等会议审稿人。

教育经历

博士	北京大学，计算机学院，计算机应用技术专业 研究方向：具身智能场景下的多模态感知融合与自适应行动决策 关注领域：具身智能、VLA、世界模型、VLM	2022.09 – 2027.06
本科	北京航空航天大学，电子信息工程学院，电子信息工程专业 荣誉：北航信息大类本科生最高荣誉（前 0.3%）、电子信息工程学院本科生最高荣誉（前 3%）、校级优秀毕业生（专业前 10%）	2018.09 – 2022.06

实习经历

米哈游，游戏 AI 算法研究员	中国北京、上海 2026.07 – 至今
- 参与设计“大脑 + 小脑”快慢双系统架构：高层“大脑”负责语义理解、长程规划与复杂决策，低层“小脑”负责低延迟动作选择与执行，兼顾跨场景泛化、复杂场景推理与实时响应。 - 系统审查外部数据样例，与团队协同迭代多版数据采集与质量验收标准，并开展首批数据的验收与质量校验。 - 研究游戏场景与资产的结构化表征并开发场景表征编码器，将结构化信息转换为多模态模型可直接利用的输入，探索替代智能体侧 RGB 观测流、无需额外 RGB 渲染链路的部署方案。 - 搭建初步评测环境与验证流程，用于评估代表性场景下的模型行为、动作执行与部署可行性。	
北京人形机器人创新中心，研究实习生	中国北京 2026.03 – 2026.06
- 针对长视频生成中的时序不一致与记忆漂移，设计具身场景记忆系统，提升长程生成稳定性。 - 基于记忆系统构建 World Action Model，增强机器人长程任务中的动作规划与生成一致性。 - 探索将第一视角 (Egocentric) 人手数据与机器人数据联合融入世界模型预训练，提升预训练表现。 - 分别构建两类数据的质量验收与清洗流水线，并深度集成至现有数据处理流程。	
至简动力（联合实验室：至简动力 & 北京大学），研究实习生	中国北京 2025.09 – 2026.02
- 采用以隐空间推理为核心的快慢双系统架构，优化全身控制与移动-操纵耦合；融合关节力矩等本体感知信号，并引入 Human-in-the-Loop 强化学习持续优化真实场景策略。 - 深度参与两代轻量化第一视角人手数据采集手套的端到端设计。两代均使用 ZED 2i 主视角与双腕部 Insta360 GO 3S，并配套开发 Unity 数采软件，实现采集可视化与三相机时间戳同步。 - 第一代采用磁定位估计腕部位姿与多 IMU 采集手指关节状态；第二代改用 SLAM 并	

精简 IMU，通过动作重定向与精度验证保持关节点定位精度，同时显著降低硬件成本并改善腕部定位丢帧。

- 将多任务、多视角人手数据融入 VLA 预训练与下游训练，提升 OOD 场景泛化能力。
- 完成 Galaxea R1 Lite 与 Franka Emika Panda 的端到端部署，覆盖真机数据采集与清洗、模型训练、测试和验证；参与 i7 Pro 移动底盘与双臂系统联调。
- 设计并制作多款定制 3D 打印机器人零部件，支持快速结构迭代与真机系统调试。

北京智源人工智能研究院 (BAAI)，具身多模态大模型研究中心，研究实习生

- 共同建设 RoboBrain 1.0/2.0，增强 LLM/VLM 的空间理解与时序建模能力。
- 共同提出端到端移动操作 VLA 方法 **AC-DiT**，在多个基准上达到 SOTA。
- 参与构建 **RoboMIND (RSS 2025)**：10.7 万条示范轨迹、4 种机器人本体、479 项任务、96 类物体，以及 5,000 条带失败原因标注的真机失败示范与 Isaac Sim 数字孪生环境。
- 负责松灵 Mobile ALOHA 与睿尔曼 RM65-B-V 复合式单臂升降机器人的硬件联调和真机数据采集。
- 构建覆盖 SAPIEN、MuJoCo、CoppeliaSim、Isaac Sim 的移动操作数据集与评测基准，搭建 VR/SpaceMouse 遥操作数采流水线，并主导 100+ 物体、10+ 场景的跨仿真器数字资产建设。

中国北京
2024.08 – 2025.08

研究成果

AC-DiT: Adaptive Coordination Diffusion Transformer for Mobile Manipulation

NeurIPS 2025

提出端到端移动操作 VLA 框架与“粗粒度预测 + 扩散精修”两阶段动作生成机制；负责核心模块实现及仿真、真机系统评测。

LaST-HD: Learning Latent Physical Reasoning from Scalable Human Data for Robot Manipulation

arXiv 2026
Technical Report

参与提出人到机器人动作学习框架，在共享 latent 物理推理空间中对齐非配对人手与机器人示范；结合作业条件世界模型、低成本 OOL Glove 与渐进式混合训练，实现跨本体数据高效迁移。

HDR: Hierarchical Denoising for Multi-Step Visual Reasoning and Robotic World Action Modeling

RSS 2026 Workshop
最佳论文奖

参与提出分层去噪框架，以由粗到细的树状 latent 实现全局一致的多步视觉推理；相比流式自回归基线显著提升成功率，推理速度较双向扩散快 54.2 倍，并迁移至实体机器人交互。

RoboMIND: Benchmark on Multi-embodiment Intelligence Normative Data for Robot Manipulation

RSS 2025

参与构建覆盖 10.7 万条示范、479 项任务、96 类物体与 4 种机器人本体的多本体遥操作数据集及基准，验证其对 VLA 成功率与泛化能力的提升。

LaST-R1: Reinforcing Robotic Manipulation via Adaptive Physical Latent Reasoning

arXiv 2026
Technical Report

参与提出面向 latent reasoning-before-acting VLA 的强化学习后训练框架；LAPO 联合优化自适应 latent Chain-of-Thought 与动作生成，在 LIBERO 上达到 99.9% 平均成功率，并在四项真机任务中相较监督微调最高提升 22.5%。

EchoArena: Learning World Models for Reliable VLA Policy Evaluation

CVPR 2026
Workshop

参与提出面向 VLA 策略闭环评测的 evaluator-centric 世界模型，结合运动学预训练、失败数据与关节空间本体感知，在 10 项任务、3 种本体上评测 5 个策略，得到更贴近真机结果的策略排序。

Chain of Thought Prompt Tuning in Vision Language Models

arXiv 2023

参与提出视觉语言模型的 Chain-of-Thought prompt tuning 方法，在图像分类、图文检索与视觉问答任务中提升泛化、迁移与推理能力。

Group-of-Latents: Perceptual Video Compression at Extreme Bitrates via Masked Latent Generative Modeling

ACM MM 2026

参与提出生成式视频压缩框架，在因果 latent 空间中分离帧内感知锚点与帧间生成，在低于 0.005 bpp 的极低码率下实现领先的感知质量并保持时间一致性。

Implicit Neural Image Field for Biological Microscopy Image Compression

Nature

Computational Science

参与提出基于隐式神经表示的自适应显微图像压缩流程，支持任意形状图像与像素级解压，在真实数据上实现最高 512 倍可控压缩率。

开源项目

CAMEL: Communicative Agents for Mind Exploration of LLM Society

Contributor | 17.6k stars

设计面向 RoboTwin 具身任务的 Agent Tools 与 Prompt 方案，支持 Zero-shot 与 One-shot 执行；相比代表性 VLA 模型展现更强的未见任务完成能力与快速适应能力。

AC-DiT: Adaptive Coordination Diffusion Transformer

NeurIPS 2025 | 49 stars

负责多模态输入、两阶段动作生成等核心模块的实现与工程化，并构建仿真及真实机器人评测脚本和配置。

Awesome-World-Models

Maintainer | 2.0k stars

持续维护世界模型研究资源，系统整理视频预测、动作条件动态建模、具身智能与强化学习等方向的代表性工作。

专业技能

- **智能体系统研发与长程任务实践**：熟悉 VLA、World Action Model (WAM) 等多模态智能体架构，具备系统设计、训练评测与部署经验；面向长程任务中的记忆漂移、误差累积与实时执行问题，能够通过分层快慢系统、世界模型与记忆增强等方法设计可落地方案。
- **机器人系统与真机部署**：熟悉 AgileX Mobile ALOHA、RealMan RM65-B-V、Galaxea R1 Lite、Franka Emika Panda 与至简动力 i7 Pro；覆盖硬件联调、遥操作、数据采集与清洗、模型训练、评测和部署闭环。
- **机器人仿真与评测**：熟悉 SAPIEN、MuJoCo、CoppeliaSim、Isaac Sim，具备跨仿真器数据集、数字资产、评测基准及 VR/SpaceMouse 遥操作流水线建设经验。
- **人手数据采集与跨本体迁移**：参与两代第一视角数据采集手套的软硬件设计，涵盖磁定位、IMU、SLAM 等传感器集成、多相机同步与 Unity 数采软件；具备动作重定向及人手示教向真机训练迁移经验。
- **工程与研究工具链**：熟练使用 Python、C/C++、PyTorch、ROS/ROS2，具备复杂研究代码库的工程化实现、复现、系统集成与端到端部署经验。

荣誉奖项

校级三好学生、校级优秀团员、学科竞赛奖学金特等奖、学习优秀奖学金一等奖、创新创业奖学金一等奖、学生工作奖学金二等奖。

其他

参与发明专利

- 一种特定目标的多摄像机联动实时分析方法。
- 一种地面摄像机固定监控和天空移动无人机联动分析方法。

参与软件著作权

- 天地一体化视频大数据离线检索与轨迹回放系统。
- 天地一体化智能人车目标实时与离线跟踪方法。
- 天地一体化智能监控平台。

学生工作：曾任北京大学视频与视觉技术国家工程研究中心班长、团支书；曾任北航党委宣传部学生记者。

个人兴趣：羽毛球、摄影。